

Análisis de Serie de Tiempo

Camilo Enrique Argoty Pulido y Verónica Estela Pastor

Especialización en Inteligencia Artificial

29 de agosto de 2024



Descomposición de series de tiempo

La descomposición de Hodrick-Prescott

El **Filtro Hodrick-Prescott** descompone una serie de tiempo y_t en una componente de tendencia τ_t y una componente cíclica c_t .

$$y_t = \tau_t + c_t$$

La descomposición de Hodrick-Prescott

El **Filtro Hodrick-Prescott** descompone una serie de tiempo y_t en una componente de tendencia τ_t y una componente cíclica c_t .

$$y_t = \tau_t + c_t$$

Aquí, cíclica se refiere a una serie que puede tener comportamientos repetitivos pero que no necesariamente es estacional.

La descomposición de Hodrick-Prescott

El **Filtro Hodrick-Prescott** descompone una serie de tiempo y_t en una componente de tendencia τ_t y una componente cíclica c_t .

$$y_t = \tau_t + c_t$$

Aquí, cíclica se refiere a una serie que puede tener comportamientos repetitivos pero que no necesariamente es estacional.

Estas componentes se determinan minimizando la siguiente función cuadrática, donde λ es un parámetro de suavizamiento:

$$\min_{\{\tau_t\}} \sum_{t=1}^T c_t^2 + \lambda \sum_{t=1}^T [(\tau_t - \tau_{t-1}) - (\tau_{t-1} - \tau_{t-2})]^2$$

La descomposición ETS

Similar a la descomposición de Hodrick-Prescott, la **Descomposición ETS** (Error-Trend-Stationality) descompone una serie de tiempo en una componente de tendencia, una componente estacional y una componente de error.

La descomposición ETS

Similar a la descomposición de Hodrick-Prescott, la **Descomposición ETS** (Error-Trend-Stationality) descompone una serie de tiempo en una componente de tendencia, una componente estacional y una componente de error.

Si el modelo es aditivo, estas componentes se suman. Si el modelo es multiplicativo, las componentes se multiplican.

Media móvil

Media móvil simple

La **Media Móvil Simple** es el promedio de los anteriores k datos:

Media móvil simple

La **Media Móvil Simple** es el promedio de los anteriores k datos:

$$SMA_k(i) = \frac{1}{k} \sum_{j=i-k+1}^i y_j$$

Exponentially Weighted Moving Average (EWMA)

El SMA tiene algunas desventajas:

Exponentially Weighted Moving Average (EWMA)

El SMA tiene algunas desventajas:

- No alcanza los picos ni los valles de la señal

Exponentially Weighted Moving Average (EWMA)

El SMA tiene algunas desventajas:

- No alcanza los picos ni los valles de la señal
- No es muy bueno para hacer predicciones. Sólo describe los datos

Exponentially Weighted Moving Average (EWMA)

El SMA tiene algunas desventajas:

- No alcanza los picos ni los valles de la señal
- No es muy bueno para hacer predicciones. Sólo describe los datos
- Valores extremos lo afectan significativamente

Exponentially Weighted Moving Average (EWMA)

El SMA tiene algunas desventajas:

- No alcanza los picos ni los valles de la señal
- No es muy bueno para hacer predicciones. Sólo describe los datos
- Valores extremos lo afectan significativamente

El **Promedio Móvil Ponderado Exponencial** (EWMA por sus siglas en inglés) supera algunos de estos problemas.

Exponentially Weighted Moving Average (EWMA)

El SMA tiene algunas desventajas:

- No alcanza los picos ni los valles de la señal
- No es muy bueno para hacer predicciones. Sólo describe los datos
- Valores extremos lo afectan significativamente

El **Promedio Móvil Ponderado Exponencial** (EWMA por sus siglas en inglés) supera algunos de estos problemas. La fórmula del EWMA es:

Exponentially Weighted Moving Average (EWMA)

El SMA tiene algunas desventajas:

- No alcanza los picos ni los valles de la señal
- No es muy bueno para hacer predicciones. Sólo describe los datos
- Valores extremos lo afectan significativamente

El **Promedio Móvil Ponderado Exponencial** (EWMA por sus siglas en inglés) supera algunos de estos problemas. La fórmula del EWMA es:

$$y_t = \frac{\sum_{i=0}^t w_i x_{t-i}}{\sum_{i=0}^t w_i},$$

Exponentially Weighted Moving Average (EWMA)

El SMA tiene algunas desventajas:

- No alcanza los picos ni los valles de la señal
- No es muy bueno para hacer predicciones. Sólo describe los datos
- Valores extremos lo afectan significativamente

El **Promedio Móvil Ponderado Exponencial** (EWMA por sus siglas en inglés) supera algunos de estos problemas. La fórmula del EWMA es:

$$y_t = \frac{\sum_{i=0}^t w_i x_{t-i}}{\sum_{i=0}^t w_i},$$

donde $w_i = (1 - \alpha)^i$, para algún α .

Exponentially Weighted Moving Average (EWMA)

El SMA tiene algunas desventajas:

- No alcanza los picos ni los valles de la señal
- No es muy bueno para hacer predicciones. Sólo describe los datos
- Valores extremos lo afectan significativamente

El **Promedio Móvil Ponderado Exponencial** (EWMA por sus siglas en inglés) supera algunos de estos problemas. La fórmula del EWMA es:

$$y_t = \frac{\sum_{i=0}^t w_i x_{t-i}}{\sum_{i=0}^t w_i},$$

donde $w_i = (1 - \alpha)^i$, para algún α . Este número se denomina **factor de suavizamiento**

Métodos de Holt-Winters

Método de Holt

También conocido como **Suavizamiento Doble Exponencial**, introduce un nuevo factor de suavizamiento:

Método de Holt

También conocido como **Suavizamiento Doble Exponencial**, introduce un nuevo factor de suavizamiento:

$$\begin{aligned}
 l_t &= (1 - \alpha)l_{t-1} + \alpha x_t, && \text{nivel} \\
 b_t &= (1 - \beta)b_{t-1} + \beta(l_t - l_{t-1}), && \text{tendencia} \\
 y_t &= l_t + b_t, && \text{modelo ajustado} \\
 \hat{y}_{t+h} &= l_t + hb_t, && \text{modelo de predicción,}
 \end{aligned}$$

Método de Holt

También conocido como **Suavizamiento Doble Exponencial**, introduce un nuevo factor de suavizamiento:

$$l_t = (1 - \alpha)l_{t-1} + \alpha x_t,$$

nivel

$$b_t = (1 - \beta)b_{t-1} + \beta(l_t - l_{t-1}),$$

tendencia

$$y_t = l_t + b_t,$$

modelo ajustado

$$\hat{y}_{t+h} = l_t + hb_t,$$

modelo de predicción,

donde h es el número de periodos en el futuro.

Método de Holt-Winters

También conocido como **Suavizamiento Triple Exponencial**, introduce un nuevo factor de suavizamiento:

Método de Holt-Winters

También conocido como **Suavizamiento Triple Exponencial**, introduce un nuevo factor de suavizamiento:

$$l_t = (1 - \alpha)l_{t-1} + \alpha x_t, \quad \text{nivel}$$

$$b_t = (1 - \beta)b_{t-1} + \beta(l_t - l_{t-1}) \quad \text{tendencia}$$

$$c_t = (1 - \gamma)c_{t-L} + \gamma(x_t - l_{t-1} - b_{t-1}) \quad \text{estacional}$$

$$y_t = (l_t + b_t)c_t \quad \text{modelo ajustado}$$

$$\hat{y}_{t+m} = (l_t + mb_t)c_{t-L+1+(m-1)modL} \quad \text{modelo de predicción,}$$

donde m es el número de periodos en el futuro

Método de Holt-Winters

También conocido como **Suavizamiento Triple Exponencial**, introduce un nuevo factor de suavizamiento:

$$l_t = (1 - \alpha)l_{t-1} + \alpha x_t, \quad \text{nivel}$$

$$b_t = (1 - \beta)b_{t-1} + \beta(l_t - l_{t-1}) \quad \text{tendencia}$$

$$c_t = (1 - \gamma)c_{t-L} + \gamma(x_t - l_{t-1} - b_{t-1}) \quad \text{estacional}$$

$$y_t = (l_t + b_t)c_t \quad \text{modelo ajustado}$$

$$\hat{y}_{t+m} = (l_t + mb_t)c_{t-L+1+(m-1)modL} \quad \text{modelo de predicción,}$$

donde m es el número de periodos en el futuro donde h es el número de periodos en el futuro.